

Detección y clasificación automática de registros acústicos de embarcaciones.

*Tesis final presentada para obtener el título de
Ingeniero de Sonido de la Universidad Nacional de Tres
de Febrero (UNTREF)*

TESISTA: Tomás Martín (38416291)
TUTOR/A: Ing. Alexander Marino
COTUTOR/A: Dra. Vanesa Reyes

AGRADECIMIENTOS

En primer lugar, debo agradecer a la Universidad Nacional de Tres de Febrero y en particular a los coordinadores de la carrera de Ingeniería de Sonido por generar un espacio donde adquirir conocimientos variados y profundos del fenómeno sonoro. Gracias a todas las personas que fueron partícipes de mi formación académica directa o indirectamente.

Un sentido agradecimiento al Grupo de Investigación de Acústica Subacuática (GIAS) por introducir y transmitir su vocación por esta ciencia. Al personal de la Fundación Cethus por acercar las inquietudes y necesidades que dieron lugar a la presente investigación. A mi tutor, Ing. Alexander Marino y cotutora, Dra. Vanesa Reyes por guiarme durante todo este proceso.

Gracias a mis amigos y compañeros por los buenos momentos compartidos. Ustedes hicieron posible el hecho de poder recorrer toda una carrera universitaria estando lejos de mis familiares. En especial a Ciro Martinez, con quien pude compartir todos estos años de estudio.

Por último pero no menos importante, quiero agradecer a mi familia que, a pesar de la distancia, me brindó su incondicional apoyo durante todo este trayecto. En particular a mi madre Rosana por haberme dado el cariño y motivación para alcanzar mis metas.

DEDICATORIA

Elige a quién o a qué quieres dedicárselo

Elegir el motivo de la dedicatoria (orientativo)

ÍNDICE DE CONTENIDOS

RESUMEN	VI
ABSTRACT	VII
1. INTRODUCCIÓN	1
1.1. FUNDAMENTACIÓN.....	1
1.2. OBJETIVOS.....	2
1.2.1. OBJETIVO GENERAL.....	2
1.2.2. OBJETIVOS ESPECÍFICOS.....	2
1.3. ESTRUCTURA DE LA INVESTIGACIÓN.....	3
2. ESTADO DEL ARTE Y MARCO TEÓRICO	4
2.1. IMPACTO ANTROPOGÉNICO EN FAUNA MARINA.....	4
2.2. ACÚSTICA SUBACUÁTICA.....	5
2.3. RUIDO ANTROPOGÉNICO MARINO	5
2.4. TRANSPORTE MARÍTIMO	6
2.4.1. RUIDO DE EMBARCACIONES.....	8
2.4.2. RUIDO DE HÉLICE	9
2.4.3. RUIDO DE MAQUINARIA.....	10
2.4.4. RUIDO POR FLUJO DE AGUA.....	11
2.4.5. COMBINACIÓN DE FUENTES.....	11
2.5. DESCRIPTORES ACÚSTICOS	12
2.5.1. ENERGÍA POR TERCIOS DE OCTAVA	13
2.5.2. CENTROIDE ESPECTRAL	13
2.5.3. FIRMA ACÚSTICA.....	13
2.6. REPRESENTACIÓN DIGITAL DE SEÑALES.....	14
2.6.1. FRECUENCIA DE MUESTREO.....	14
2.6.2. DECIMACIÓN	14
2.6.3. NORMALIZACIÓN	15
2.7. ALGORITMOS DE DETECCIÓN Y CLASIFICACIÓN EN GRANDES BASES DE DATOS	15
2.8. APRENDIZAJE AUTOMÁTICO.....	16
2.8.1. APRENDIZAJE PROFUNDO	17
2.8.2. MEDIDAS DE DESEMPEÑO.....	17
3. DISEÑO DE LA INVESTIGACIÓN, VARIABLE Y MUESTRA	19
3.1. MANEJO DE DATOS	20

3.2. COMPOSICIÓN DE LA BASE DE DATOS.	21
3.3. ESTUDIO DE DESCRIPTORES.....	23
3.4. DESARROLLO Y EXPERIMENTACIÓN CON ALGORITMOS.	24
3.4.1. DETECTOR AUTOMÁTICO DE EVENTOS ACÚSTICOS TONALES.	24
3.4.2. PRE-PROCESAMIENTO.....	27
3.4.3. DETECTOR AUTOMÁTICO DE EMBARCACIONES.	29
3.4.4. CLASIFICADOR DE EMBARCACIONES.....	30
4. RESULTADOS.....	31
4.1. DETECTOR AUTOMÁTICO DE EVENTOS ACÚSTICOS TONALES.	31
4.2. CARACTERIZACIÓN DE SEÑALES.....	31
4.3. DETECTOR AUTOMÁTICO DE EMBARCACIONES.	33
4.3.1. ESTUDIO DE DESCRIPTORES.....	35
4.3.2. TAMAÑO DE BASE DE DATOS.	37
5. Conclusiones.....	40
6. Líneas futuras de investigación	41
BIBLIOGRAFÍA.....	42

ÍNDICE DE FIGURAS

Figura 1.	Espectrogramas de distintos tipos de barcos [28].	7
Figura 2.	Representación gráfica de las fuentes de ruido en un barco.	8
Figura 3.	Representación gráfica de los tipos de cavitación en la hélice.	9
Figura 4.	Cavitación de vórtice en la punta.....	10
Figura 5.	Representación gráfica del proceso de decimación.	14
Figura 6.	Diagrama en bloques del diseño de la investigación.	19
Figura 7.	Diagrama entidad-relación de la BDR.	21
Figura 8.	Ejemplo de detección visual de embarcaciones en software Raven Pro 1.6. Representación completa (arriba) y representación de su contenido tonal (abajo).	25
Figura 9.	Diagrama en bloques del algoritmo de detección de señales tonales.	26
Figura 10.	Representación del proceso de detección de picos. Respuesta en frecuencia del archivo completo (azul), respuesta en frecuencia de fragmento con señal de interés (rojo) y detecciones de picos (cruces).	27
Figura 11.	Representación precisión de detección en función de la cantidad de epochs. 34	
Figura 12.	Representación del error de detección en función de la cantidad de epochs. 34	
Figura 13.	Representación de la exactitud del modelo en función la variación de cientos de muestras del conjunto de registros de embarcaciones.....	38

ÍNDICE DE TABLAS

Tabla 1.	Descriptores acústicos subacuáticos.....	12
Tabla 2.	Media \pm desvío estándar para frecuencia 5% y centroide espectral. Mediana (Q1-Q3) para el resto de los descriptores.....	32
Tabla 3.	Resultados de experimentación con distintas estructuras de redes neuronales.	33
Tabla 4.	Resultados de experimentación descartando de a un parámetro.	35
Tabla 5.	Resultados de experimentación descartando a Fc y otro parámetro.....	36

ÍNDICE DE ANEXO

ANEXO I..... 1

ÍNDICE DE FIGURAS ANEXO

No se encuentran elementos de tabla de ilustraciones.

ÍNDICE DE TABLAS ANEXO

TABLA A1. RESUMEN DE CARACTERÍSTICAS SONORAS DEL RUIDO ANTROPOGÉNICO MARINO. ¡ERROR! MARCADOR NO DEFINIDO.

RESUMEN

ABSTRACT

Keywords

1. INTRODUCCIÓN

1.1. FUNDAMENTACIÓN

El ruido producto de la actividad humana, conocido como antropogénico, es cada vez mayor en los mares y océanos del mundo. Los eventos sonoros de cortos períodos de tiempo y alta intensidad han sido objeto de estudio debido a su potencial para causar lesiones físicas en mamíferos marinos [1-3]. Sin embargo, el incremento del transporte marítimo supone una exposición a ruidos de baja intensidad en largos períodos de tiempo lo que resulta en consecuencias potencialmente graves en una variedad de organismos marinos, incluidos mamíferos, peces y cefalópodos [4-6]. Algunos de los efectos que producen son: enmascaramiento de sonidos biológicamente significativos, estrés crónico, modificación en la conducta y cambios en la atención [7-10]. Esta es la razón por la cual se debe prestar especial atención en la actividad antropogénica en el mar.

Dentro del territorio argentino, la Fundación Cethus¹ es una de las principales organizaciones sin fines de lucro encargadas de investigar, monitorear, estudiar y divulgar conocimiento sobre los distintos tipos de cetáceos del Mar Argentino para su conservación. Desde el año 2010, la fundación implementa métodos de monitoreo que buscan caracterizar señales acústicas subacuáticas [11]. En la actualidad, en conjunto con el Grupo de Investigación de Acústica Submarina (GIAS) de la Universidad Nacional de Tres de Febrero (UNTREF), se encuentra en etapa de desarrollo de una sonoboya autónoma de Monitoreo Acústico Pasivo (PAM) que registre eventos sonoros (tanto de cetáceos como antropogénicos) para enviarlos automáticamente a un servidor en la nube con el cual se permite el procesamiento remoto de la información.

En la presente investigación se analizan las características acústicas de distintos sonidos de embarcaciones. Dichos eventos se buscan a partir de una inspección visual de espectrogramas de registros sonoros provenientes de diversas fuentes. En primer lugar, se analizan las grabaciones recolectadas por Fundación Cethus durante la campaña antártica (2014-2020). En segundo lugar, a partir de una intensiva búsqueda, se intenta encontrar posibles bases de datos de acceso público en internet. Además, se establece

¹ Fundación Cethus es una ONG argentina que trabaja en investigación y conservación de cetáceos.

comunicación con los autores de trabajos similares solicitando el acceso a sus bases de datos de este tipo de registros de forma colaborativa.

Se pretende encontrar particularidades que permitan detectar y clasificar entre distintos tipos de embarcaciones. Sobre la base de la investigación realizada, se desarrolla un algoritmo de detección y clasificación automática de los distintos ruidos producidos por el hombre. El lenguaje utilizado para realizar este algoritmo es Python basándose en la herramienta de computación conocida como Aprendizaje Automático (Machine Learning). A partir de este desarrollo, se busca almacenar únicamente eventos sonoros de interés y de esta forma reducir significativamente tanto la memoria de registro de datos como la energía necesaria para el envío de la información al servidor en el marco del proyecto que está desarrollando la fundación.

En una primera instancia se genera una base de datos conformada tanto por señales de audio registradas en la campaña antes mencionada como por grabaciones provenientes de otras fuentes. Luego, mediante un análisis exhaustivo de las señales acústicas recolectadas, se definen descriptores que mejor caractericen a los eventos sonoros propios de las distintas actividades antropogénicas. Posteriormente, se desarrolla un algoritmo capaz de detectar y clasificar automáticamente el ruido inducido por el hombre.

1.2. OBJETIVOS

1.2.1. OBJETIVO GENERAL

El objetivo principal de esta investigación es detectar, reconocer y discriminar sonidos provenientes por distintos tipos de embarcaciones a partir de un algoritmo computacional que se implementará en un sistema subacuático de monitoreo pasivo autónomo.

1.2.2. OBJETIVOS ESPECÍFICOS

- Crear la base de datos con registros sonoros recolectados en la campaña Antártica y de fuentes externas.

- Analizar características espectrales y temporales del ruido antropogénico submarino.
- Clasificar de los distintos tipos de ruidos.
- Establecer los descriptores que caractericen a los eventos sonoros.
- Desarrollar un algoritmo autónomo en Python capaz de detectar y clasificar el ruido inducido por el hombre mediante inteligencia artificial.
- Validar el sistema de detección automático desarrollado.
- Realizar propuestas de mejora a implementar.

1.3. ESTRUCTURA DE LA INVESTIGACIÓN

En el presente capítulo se exponen los fundamentos principales que movilizan esta tesis de grado. Se introduce a la problemática, se explican las razones por las cuales resulta importante el abordaje del tema, se especifica el objetivo general y sus correspondientes objetivos específicos.

En el segundo capítulo se expone tanto una revisión del estado del arte de las principales investigaciones llevadas a cabo en el estudio del ruido antropogénico subacuático como el marco teórico necesario para la elaboración y correcta comprensión de la presente investigación. El marco teórico está dividido en tres secciones. En primer lugar, se describen los distintos eventos acústicos generados por la actividad humana en el mar. Luego se presentan descriptores que son comúnmente utilizados en acústica subacuática. Por último, se muestran principios y consideraciones a tener en cuenta en el aprendizaje automático y, dentro de este, las redes neuronales profundas.

En el tercer capítulo se muestra el procedimiento llevado a cabo en la investigación. En primer lugar, se realiza un estudio exhaustivo de las señales de interés. Luego, se desarrolla la base de datos. Por último se diseña y valida el algoritmo del detector y clasificador.

2. ESTADO DEL ARTE Y MARCO TEÓRICO

2.1. IMPACTO ANTROPOGÉNICO EN FAUNA MARINA

Como se informa en la introducción de la presente investigación, el incremento de la actividad humana en los océanos supone un impacto negativo sobre la fauna marina. Por lo tanto, resulta imprescindible recopilar información acústica que permita estimar el nivel de daño producido por la degradación en el paisaje sonoro en determinadas regiones. La recopilación de estos datos debe ser a largo plazo y en grandes extensiones del océano para permitir inferir si el incremento de nivel de ruido afecta la distribución y/o las actividades de las distintas especies marinas.

Los avances en la detección automatizada de eventos sonoros permiten el rápido procesamiento de grandes volúmenes de datos, incluidas vocalizaciones de animales y el sonido antropogénico que pueden ser relevantes para políticas de conservación medioambiental. Esta información es especialmente valiosa para la investigación y la gestión de los ecosistemas marinos, en los que la detección visual de especies puede ser considerablemente más difícil que en los ecosistemas terrestres [12]. Comúnmente, en el proceso de una evaluación de impacto ambiental (EIA) es necesario el modelado y la predicción de huellas de ruido de operaciones antropogénicas específicas.

En la actualidad, se han desarrollado diversas herramientas que permiten reconocer sonidos de casos particulares de animales. Pero PAM no es solo una herramienta que permite el seguimiento de la fauna marina, sino también el desarrollo de actividades antropogénicas y los paisajes sonoros marinos en general.

Por otro lado, no existe a nivel nacional e internacional regulación de mediciones y análisis de información bioacústica para realizar una EIA en un contexto subacuático. Ante esta problemática, PAM se presenta como una herramienta viable para el monitoreo a largo plazo en ubicaciones remotas. De esta forma se obtiene información confiable, comparable y objetiva con la cual sea posible desarrollar una metodología estandarizada de evaluación [13].

2.2. ACÚSTICA SUBACUÁTICA

Una fuente es considerada puntual si la energía decae proporcionalmente al cuadrado de la distancia. Para que esto sea posible, la misma debe encontrarse suficientemente lejos de la superficie del agua y el fondo. Si la profundidad del mar no es considerablemente grande, debido a las reflexiones que se producirán, la energía se propaga en forma cilíndrica.

El nivel de presión sonora en el aire se calcula con un valor de referencia asociado al umbral de audición humana a 1 kHz ($20 \mu\text{Pa}$) mientras que para en el agua se utiliza $1 \mu\text{Pa}$.

La velocidad de propagación de una onda acústica subacuática depende principalmente de la profundidad, temperatura y salinidad. A fines prácticos, si no se cuenta con instrumental para adquirir esta información, se suele considerar una velocidad de 1500 m/s en agua salada y 1435 m/s en agua dulce.

2.3. RUIDO ANTROPOGÉNICO MARINO

Cuando se habla de ruido, es importante tener en cuenta la diferencia entre el ambiental y el de fondo. Estos términos se usan indistintamente, pero en realidad esto no debería ocurrir. El ambiental es aquel evento sonoro que se percibe constantemente, excluido el sonido propio generado por la recepción de hidrófonos y cualquier fuente que pueda identificarse individualmente. El ruido de fondo está formado tanto por el ambiental como todos los otros sonidos identificables individuales.

Hay casos en los que un evento identificable puede considerarse ambiental porque normalmente se encuentra presente; por ejemplo, el tráfico marítimo en un puerto concurrido o un gran grupo de mamíferos marinos haciendo vocalizaciones continuas. Si bien se puede identificar la fuente general de estos, no se pueden distinguir barcos o animales individuales.

La exploración geofísica (petróleo y gas), la construcción de parques eólicos, ejercicios militares y transporte comercial, han dado como resultado niveles que se estiman en diez veces más altos en la actualidad que un hace algunas décadas [14]. Al igual que los efectos sobre la fauna marina, las características acústicas son específicas de

cada actividad. Para la presente investigación resulta de especial interés comprender particularmente el ruido antropogénico producido por embarcaciones. En la siguiente subsección se presentan algunos detalles de este evento acústico en cuestión.

2.4. TRANSPORTE MARÍTIMO

En la actualidad, los barcos son una de las principales fuentes de ruido antropogénico en el océano. Debido a que no solo aumenta la cantidad de embarcaciones sino también su tamaño y potencia de propulsión, el nivel producido también lo hace proporcionalmente. El transporte marítimo no se distribuye uniformemente por todo el océano. Este se concentra en áreas donde se encuentran rutas marítimas y puertos, principalmente en el hemisferio norte.

Si bien el sonido producido por barcos es predominantemente de baja frecuencia, también es de banda ancha debido a la cavitación producida por la rotación de hélices. Dada la naturaleza del mismo, el sonido de una sola embarcación puede viajar grandes distancias y posiblemente combinarse con otras fuentes sonoras aumentando los niveles de ruido ambiental.

En términos de grandes embarcaciones comerciales, se encuentran diferentes tipos como transporte de pasajeros y carga, buques cisterna, pesca, dragado, suministro en alta mar, rompehielos, investigación y militares, cada uno con su propia firma acústica. McKenna et al. [15] midieron niveles de presión sonora producidos por siete tipos de barcos comerciales en el Canal de Santa Bárbara. Registraron niveles de presión y combinándolo con sistemas de información de tráfico marítimo, pudieron estimar los niveles de presión que generan referenciado a 1 metro de distancia. Los niveles estimados oscilan entre 182,1 y 188,1 dB (1 μ Pa RMS - 1 m) para frecuencias entre 20 y 1000 Hz. Por otro lado, afirman que el ruido es generado principalmente por cavitación, presentando un pico máximo entre 50 y 150 Hz pero que puede extenderse hasta 10 kHz.

En su investigación, los autores encontraron que la radiación sonora en los barcos evaluados es asimétrica, presentando diferencias de entre 5 a 10 dB entre popa y proa. Con el fin de enriquecer la caracterización del evento sonoro, en la Figura 1 se muestran espectrogramas de 3 distintos tipos de embarcaciones.

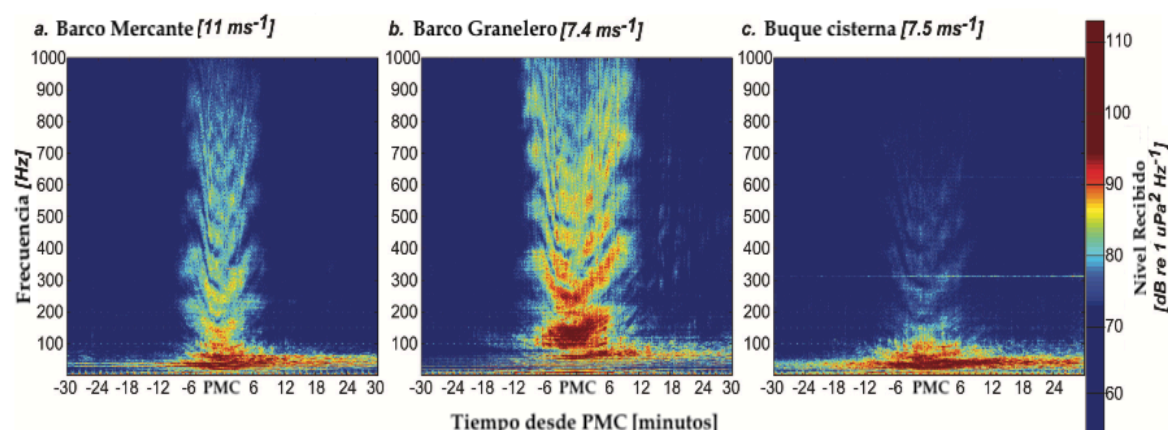


Figura 1. Espectrogramas de distintos tipos de barcos [28].

A partir de la Figura 1 puede afirmarse que el ruido generado depende considerablemente del tipo de navío. Se observan dos características principales, componentes tonales por debajo de 100 Hz y una distribución energética con forma de U por encima de esta.

Las líneas tonales son el resultado de la cavitación de las palas de la hélice y sus armónicos. Por otro lado, los patrones de interferencia en forma de U son causados por la interferencia constructiva y destructiva producto de interacciones entre distintos caminos de propagación (sonido directo y reflejado en la superficie) [16]. Este fenómeno es conocido como efecto espejo de Lloyd y depende de la profundidad de la fuente y el receptor, la distancia de la fuente al receptor, las propiedades de la columna de agua y la reflexión del fondo [17].

Jensen et al. [18] midieron niveles de ruido de dos embarcaciones pequeñas utilizadas habitualmente con fines recreativos en zonas costeras. Como resultado obtuvieron niveles de presión entre 138 y 152 dB (1 μ Pa RMS - 1 m) para frecuencias entre 0,2 a 40 kHz. Por otro lado, al analizar la distribución energética de las señales encontraron que si bien sigue siendo predominantemente en bajas frecuencias cuenta con mayor proporción de energía por encima de 1 kHz en comparación con barcos de mayor tamaño.

El potencial de propagación a larga distancia del ruido de baja frecuencia generado por embarcaciones comerciales supone un gran riesgo para mamíferos marinos. En particular, cetáceos que se comunican a bajas frecuencia corren riesgo de

enmascaramiento y como consecuencia podrían colisionar. Este problema es evitable al diseñar rutas de navegación que no sean coincidentes con áreas claves para el normal desarrollo de la vida marina.

2.4.1. RUIDO DE EMBARCACIONES

En general, la hélice y propulsor son las fuentes de ruido preponderante para la mayoría de las embarcaciones. En particular, las que operan a alta potencia o las que operan con hélices de velocidad de rotación constante a baja potencia a menudo tienen un ruido dominante de hélice/propulsor[19]. Los buques de baja potencia y, en particular, los que cuentan con motores diésel, a menudo tienen un ruido dominante procedente de la radiación estructural excitada por la maquinaria a bordo. Algunas embarcaciones se caracterizan por una fuerte radiación de ruido estructural debido a sistemas hidráulicos, engranajes, compresores u otra maquinaria potencialmente ruidosa. Por otro lado, las embarcaciones de alta velocidad pueden tener una fuerte radiación debido a la generación de vórtices alrededor de aberturas y discontinuidades en el casco. Los buques diseñados para producir un bajo nivel de ruido pueden tener una radiación procedente de fuentes auxiliares, como bombas, ventiladores u otras fuentes de baja potencia mecánica. Las fuentes típicas de ruido de los barcos se muestran en la Figura 2.




Figura 2. Representación gráfica de las fuentes de ruido en un barco.

2.4.2. RUIDO DE HÉLICE

El ruido de la hélice se produce por una serie de mecanismos generadores de ruido, cavitación de vórtice en la punta, diferentes tipos de cavitación de pala, cavitación de vórtice en el eje, pulsos de presión generados por las palas giratorias de la hélice y ruidos tonales debido a la resonancia entre las frecuencias naturales de las palas y los vórtices del borde de salida. En la Figura 3 se muestran diferentes tipos de ruido de cavitación.




Figura 3. Representación gráfica de los tipos de cavitación en la hélice.

El ruido de la hélice depende en gran medida de la carga. A medida que aumenta la carga en las palas de la hélice, la presión en el lado de succión se vuelve lo suficientemente baja como para que ocurra la cavitación. La cavitación de las palas es muy fluctuante y normalmente será más fuerte cerca de la parte superior del diámetro de la hélice. Además, la diferencia de presión entre el lado de succión y el lado de presión de la pala de la hélice provocará vórtices.

Las hélices pueden tener diámetros grandes de hasta casi 10 m, más comúnmente entre 2 a 6 m. Por otro lado, es común encontrarse con barcos que tienen dos hélices. En tales casos, se producirá interferencia entre los dos campos de presión y la fuente de ruido será muy direccional. En todos los casos, el campo de presión se reflejará desde el casco y estos reflejos también interferirán con el campo de presión original, lo que hará que el patrón de origen sea bastante complejo. Los fenómenos de interferencia generalmente

solo tienen importancia en el dominio de baja frecuencia que involucra la frecuencia de paso de la pala y los dos o tres armónicos más altos de la frecuencia de paso de la pala.




Figura 4. Cavitación de vórtice en la punta.

2.4.3. RUIDO DE MAQUINARIA

Una embarcación contiene una gran cantidad de maquinaria generadora de ruido. Parte de la misma está acoplada a tuberías, conductos o pozos que transmiten la energía del ruido por estructuras o fluidos sobre grandes áreas. Todas estas fuentes de ruido están contenidas en un casco parcialmente sumergido en agua. La transmisión de vibraciones estará fuertemente influenciada por la interacción entre la fuente y las placas sumergidas de la carcasa, así como las frecuencias de resonancia de las mismas. Finalmente, la vibración de las placas provoca fluctuaciones de presión en el agua, algunas de las cuales se irradian como sonido al campo lejano. El ruido de baja frecuencia puede estar asociado con la vibración global de grandes áreas del casco que se mueven en fase a una misma frecuencia, mientras que los modos de vibración locales de áreas más pequeñas del casco serán más típicos para la vibración a frecuencias más altas. Para embarcaciones de baja potencia o para embarcaciones con maquinaria firmemente sujeta, la radiación de ruido estructural puede ser dominante en general o en partes del rango de frecuencia. Las fuentes de maquinaria significativas pueden estar ubicadas a lo largo del casco.

2.4.4. RUIDO POR FLUJO DE AGUA

El casco en sí, así como todos los apéndices sujetos al casco, generarán turbulencias y vórtices cuando se muevan por el agua y, en ocasiones, pueden generar un ruido significativo, especialmente a alta velocidad. Asimismo, cualquier abertura en el casco (por ejemplo, túneles de propulsión) puede generar variaciones de presión a medida que el agua pasa a través de ellas. Si la frecuencia del vórtice o la frecuencia de variación de la presión se acoplan a cualquier frecuencia natural estructural, puede surgir un fuerte ruido tonal. Dichas fuentes pueden ubicarse a lo largo de la extensión del casco y tanto el nivel como su contenido frecuencial que dependerá de la velocidad del flujo.

2.4.5. COMBINACIÓN DE FUENTES

Las diversas fuentes de ruido están ubicadas en diferentes lugares del casco, actúan a distintas profundidades, pueden variar su nivel, ubicación y el contenido de frecuencia dependiendo de las condiciones de operación. Además un barco puede tener una eslora superior a 400 m, aunque la mayoría de los barcos suelen estar en el rango de 50 a 350 m. Por todas estas razones, es muy complejo describir un barco como una fuente de ruido ideal. Por otro lado, si se registra el ruido producido desde una distancia razonablemente larga, puede parecer una fuente puntual monopolar. Sin embargo, a larga distancia, las propiedades de transmisión del mar y la influencia del ruido de fondo pueden complicar las observaciones.

La capacidad para determinar las características acústicas de las distintas fuentes depende también del ruido de fondo en la zona de grabación. Teniendo en cuenta que la pérdida por dispersión esférica teórica es de 40 dB a una distancia de 100 m, un barco relativamente silencioso puede quedar enmascarado con el ruido de fondo a una distancia de esta magnitud, mientras que un barco ruidoso puede observarse fácilmente a distancias mucho más largas.

La mayoría de los barcos se moverán a cierta velocidad durante la observación, mientras que la posición de grabación se realizarán desde una ubicación fija. Por lo tanto, el aspecto y las distancias relativas entre las diferentes fuentes de ruido y el observador cambiarán continuamente. Además, la directividad de las diferentes fuentes puede

causar una variación significativa en el nivel aparente de la fuente a medida que cambia el aspecto. Esta es la razón por la cual describir con precisión una embarcación como fuente de ruido a partir de las observaciones en el campo lejano se vuelve una tarea sumamente compleja.

2.5. DESCRIPTORES ACÚSTICOS

En la Tabla 1 se muestran distintos descriptores utilizados usualmente para el reconocimiento de señales acústicas subacuáticas.

Tabla 1. Descriptores acústicos subacuáticos

Parámetro	Definición
Frecuencia Pico (F_p) [Hz]	Frecuencia correspondiente al valor de máxima amplitud del espectro.
Frecuencia central (F_c) [Hz]	Frecuencia que divide al espectro en dos mitades con igual energía.
Centroide espectral (C_e) [Hz]	Indica la posición del "centro de gravedad" de acuerdo a las amplitudes del espectro
Ancho de banda (B_w) -3 y -10 dB [Hz]	Rango del espectro comprendido entre -3 y -10 dB por debajo del pico máximo del espectro.
Frecuencia 5% ($F_{5\%}$) [Hz]	Frecuencia que acumula el 5% de la energía.
Frecuencia 95% ($F_{95\%}$) [Hz]	Frecuencia que acumula el 95% de la energía.
Ancho de banda 90% ($B_{90\%}$) [Hz]	Diferencia entre $f_{95\%}$ y $f_{5\%}$.
Duración -10 dB (T_{10dB}) [s]	Duración de tiempo definida por el intervalo entre -10 dB anteriores y posteriores relativos al pico de la envolvente de la señal temporal.

A continuación se presentan algunas ecuaciones necesarias para calcular los parámetros acústicos utilizados en la presente investigación.

2.5.1. ENERGÍA POR TERCIOS DE OCTAVA

En la norma IEC 61260-3 [20] se definen los intervalos de frecuencias estandarizados donde se obtiene un único valor representativo de la energía que contenga cada banda. Como se muestra en la ecuación 1, se calcula como la sumatoria de la energía sobre el resultado de la DFT filtrada.

$$E(i) = \sum_{i=1}^k h(X(i)) \quad (1)$$

Donde $X(i)$ representa el valor de magnitud de cada banda de frecuencia, i representa cada una de las bandas y h representa el filtrado de la señal, en este caso en particular, por tercios de octava.

2.5.2. CENTROIDE ESPECTRAL

Es una medida muy utilizada en procesamiento de señales digitales para caracterizar un espectro. La misma está sumamente relacionada con la impresión del timbre de un sonido y se calcula mediante el uso de la ecuación 2.

$$CE = \frac{\sum_{i=0}^{N-1} f(i)X(i)}{\sum_{i=0}^{N-1} X(i)} \quad (2)$$

Donde $f(n)$ representa la frecuencia central de ese intervalo.

2.5.3. FIRMA ACÚSTICA

Una firma acústica (F_a) es la caracterización frecuencial de toda fuente sonora. Toda fuente acústica posee una distribución en frecuencia que la hace diferenciable del resto. La misma depende de cualidades físicas de generación de sonido. Por otro lado, el medio de propagación influye en la manera en que la señal acústica es captada por un receptor.

El análisis de firma acústica es un complemento importante usualmente utilizado en PAM para rastrear buques de guerra. Por lo tanto, resulta en un componente de especial interés en tareas de clasificación de distintas embarcaciones.

2.6. REPRESENTACIÓN DIGITAL DE SEÑALES.

Para el correcto procesamiento de señales acústicas resulta considerablemente importante tener en cuenta ciertos aspectos de la representación digital de las mismas.

2.6.1. FRECUENCIA DE MUESTREO

La frecuencia de muestreo se define como la tasa de muestras por segundo que se toman sobre una señal analógica. Es un factor importante a tener en cuenta ya que está directamente relacionada con la utilización de recursos computacionales y con la frecuencia máxima que puede representar la señal digital. A una mayor frecuencia de muestreo, mayor cantidad de datos para representar la señal. Por lo tanto, es posible representar frecuencias superiores pero supone un incremento en el costo computacional.

2.6.2. DECIMACIÓN

Decimar es un proceso donde se reduce la cantidad de muestras por segundo de una representación digital buscando optimizar el costo computacional de un algoritmo. En la Figura 5 se muestra ilustrativamente como se realiza el proceso de decimación.




Figura 5. Representación gráfica del proceso de decimación.

2.6.3. NORMALIZACIÓN

La normalización surge de analizar y procesar la información digital para lograr estandarización con el objetivo de trabajar sobre un rango bien definido de amplitudes. En otras palabras, mediante la normalización se busca ajustar valores medidos en diferentes escalas a una escala común con el objetivo de poder hacer comparaciones coherentes entre conjuntos de muestras. Este proceso es considerablemente necesario en sistemas de reconocimiento de patrones y particularmente en algoritmos basados en aprendizaje automático. En la presente investigación se utilizan las normalizaciones definidas en las ecuaciones 3 y 4.

$$X_n = \frac{X_n}{X_{max}} \quad (3)$$

$$X_n = \frac{X_n - \bar{X}}{s} \quad (4)$$

Donde X_n representa el valor de magnitud de cada muestra, X_{max} el valor de magnitud máxima del conjunto de muestras, \bar{X} su valor promedio y s su desvío estándar.

2.7. ALGORITMOS DE DETECCIÓN Y CLASIFICACIÓN EN GRANDES BASES DE DATOS

Durante la última década, el costo de recopilar y almacenar datos acústicos se ha reducido drásticamente, por lo que suele ser normal recopilar terabytes de información en un solo proyecto [21,22]. A medida que aumenta el volumen de datos acústicos, el proceso de extracción de información relevante se vuelve más costoso y largo.

El aprendizaje automático tiene el potencial de identificar señales de interés dentro de grandes conjuntos de datos de forma relativamente barata y con mayor consistencia que los analistas humanos [23]. Hasta el momento, en la monitorización acústica se han utilizado métodos como el análisis discriminante [24], los modelos de mezcla gaussiana [25], las máquinas de vectores de soporte [26], los árboles de clasificación y regresión [27], los bosques aleatorios [28], la codificación dispersa [29] y el aprendizaje profundo [30–32].

Las redes neuronales profundas vienen avanzando en el campo de la detección y clasificación de grandes volúmenes de información como lo son los generados por grabaciones en PAM. Se ha demostrado que las arquitecturas de aprendizaje profundo

producen bajas tasas de falsos positivos en comparación con algoritmos alternativos. Además, se ha probado que a partir de una red neuronal entrenada con grabaciones en una sola región geográfica se logra realizar generalizaciones para obtener resultados satisfactorios en distintas regiones del mundo [12]. Es por esto que se decide utilizar redes neuronales profundas como herramienta para detectar, reconocer y discriminar los distintos sonidos antropogénicos subacuáticos en la presente investigación.

2.8. APRENDIZAJE AUTOMÁTICO

El Aprendizaje Automático (también conocido como Machine Learning) es un subconjunto de Inteligencia Artificial (IA) que se centra en desarrollar sistemas que aprenden, o mejoran su rendimiento, en función de una serie de datos de entrada. Esta herramienta está fuertemente relacionada con la clasificación de datos según patrones estadísticos. Los distintos algoritmos de aprendizaje automático se dividen principalmente en dos grandes grupos en función de la salida de los mismos, los de Aprendizaje Supervisado y los de Aprendizaje no Supervisado.

El Aprendizaje Supervisado es una técnica para deducir una función a partir de datos de entrenamiento. Los mismos se conforman de a pares, datos de entrada y resultados deseados. La salida de la función puede ser un valor numérico (regresión) o una etiqueta de clase (clasificación). Por lo tanto, a partir de una serie de ejemplos (datos de entrenamiento) se crea una función capaz de otorgar resultados coherentes a cualquier entrada válida. Regresión Lineal y Logística, Clasificación Multiclase y Máquinas de Vectores soporte son algunos ejemplos de algoritmos que utilizan este modelo.

En el Aprendizaje no Supervisado, el modelo se ajusta a las observaciones. A diferencia del anterior, en este caso no se tiene información sobre los datos de entrada. El algoritmo trata a los objetos como un conjunto de variables aleatorias y busca identificar patrones o similitudes complejas a partir de las cuales separar en grupos. Agrupamiento de k-means, análisis de componentes principales e independientes, leyes de asociación y aprendizaje profundo son ejemplos de algoritmos que utilizan este modelo.

2.8.1. APRENDIZAJE PROFUNDO

Dentro del Aprendizaje Automático, el Aprendizaje Profundo (o Deep Learning en inglés) plantea un conjunto de algoritmos no lineales que pueden aplicarse para la modelización de datos y reconocimiento de patrones. La forma en la que trabaja es usando varias capas de redes neuronales (unidades de procesamiento) en cascada que permiten la extracción y transformación de variables. Dichas capas están apiladas jerárquicamente por diferentes niveles de abstracción, desde un bajo nivel hacia niveles de abstracción mas complejos.

2.8.2. MEDIDAS DE DESEMPEÑO

Para caracterizar el funcionamiento de sistemas de detección y clasificación basados en aprendizaje automático se suelen utilizar los descriptores que se presentan a continuación [34,35].

- Exactitud: Es la relación entre los resultados correctos sobre el total de los resultados obtenidos. Este parámetro en particular suele dar resultados imprecisos cuando las bases de datos están desbalanceadas.

$$Exactitud = \frac{PV + NV}{PV + NV + PF + NF} \quad (5)$$

Donde PV (positivo-verdadero) y NV (negativo-verdadero) son los resultados positivos y los negativos clasificados correctamente. PF (positivo-falso) y NF (negativo-falso) son los resultados clasificados incorrectamente.

- Precisión: Definida como la relación entre los resultados positivos correctos sobre el total de los resultados positivos obtenidos.

$$Precisión = \frac{PV}{PV + PF} \quad (6)$$

- Exhaustividad: Es la relación entre los resultados positivos correctos sobre el total de los casos positivos.

$$Exhaustividad = \frac{PV}{PV + NF} \quad (7)$$

- Valor F: Se utiliza para combinar las medidas de precisión y exhaustividad en un solo valor.

$$F = 2 \cdot \frac{Precisión \cdot Exhaustividad}{Precisión + Exhaustividad} \quad (8)$$

3. DISEÑO DE LA INVESTIGACIÓN, VARIABLE Y MUESTRA

Para el desarrollo de la presente investigación, resulta imprescindible la obtención de una gran cantidad de datos para el entrenamiento de los algoritmos. En la Figura 6 se muestra un diagrama en bloque de los pasos necesarios para el desarrollo de la presente investigación.

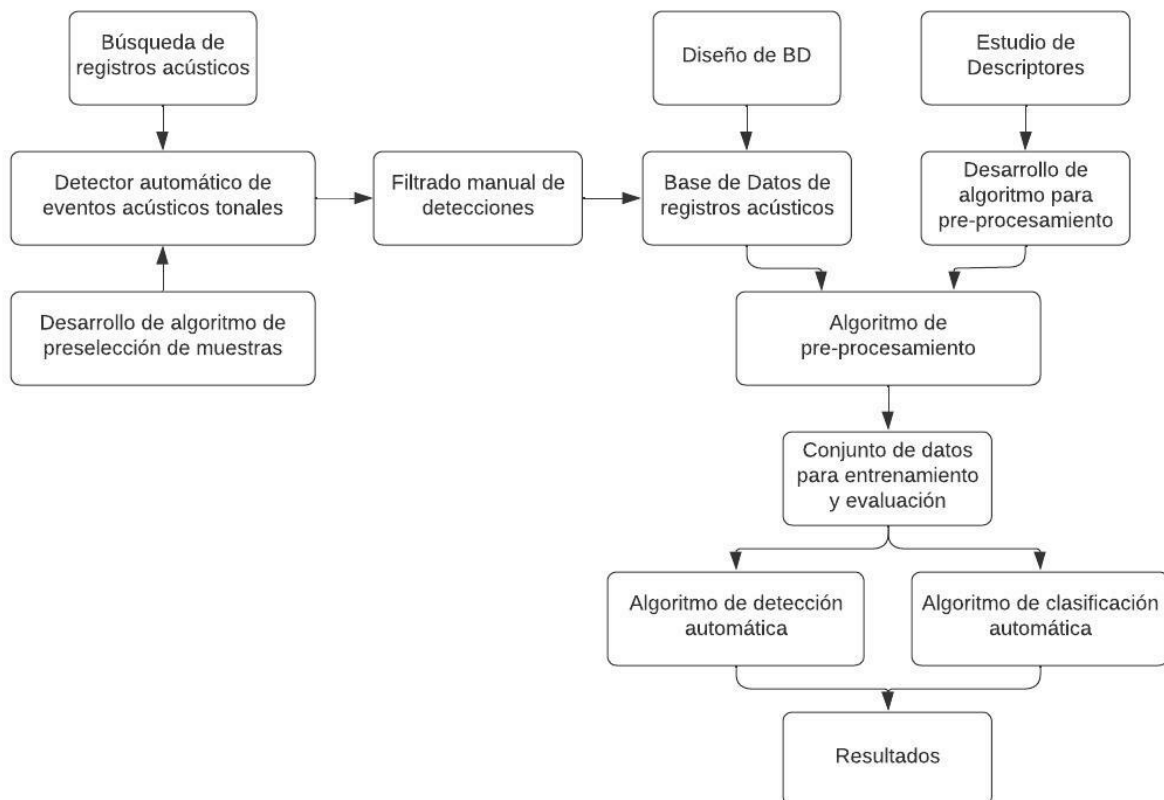


Figura 6. Diagrama en bloques del diseño de la investigación.

En primer lugar, se diseña una base de datos (BD) que estará conformada en una primer instancia por los registros sonoros subacuáticos que se consigan a partir de las grabaciones proporcionadas por la Fundación Cethus o fuentes externas.

En segundo lugar, se desarrolla un algoritmo que permite preseleccionar eventos con características acústicas similares a las que se encontrarían en registros de embarcaciones. Seguidamente, a partir inspección visual manual de los eventos preseleccionados se generan los conjuntos de datos que conformarán la base de datos.

En tercer lugar, se lleva a cabo un estudio exhaustivo de las distintas señales acústicas de interés con el fin de obtener los descriptores que permitan el desarrollo del algoritmo. A partir de esta actividad, se desarrolla un algoritmo con el objetivo de pre procesar las muestras de audio y conseguir los parámetros que conforman los conjuntos de datos de entrada para los posteriores algoritmos.

El siguiente paso es el desarrollo y evaluación del desempeño los algoritmos de detección y clasificación automática. Por último, se lleva a cabo el entrenamiento y validación a partir de los registros antropogénicos representativos del fenómeno acústico en cuestión.

3.1. MANEJO DE DATOS

En primer lugar, se lleva a cabo el diseño de la base de datos relacional (BDR) donde se almacenan los nombres de archivos y características de interés de los registros sonoros disponibles. El sistema de gestión de bases de datos que se va a utilizar en el presente desarrollo es PostgreSQL. En la Figura 7 se muestra en el diagrama de entidad - relación del diseño de la BDR a implementar.

Previo a la carga en la tabla Evento, resulta necesario crear distintas tablas a las cuales el usuario se referirá en cada detección evitando la repetición de datos en la BDR. En este caso en particular, la BDR debe contar con la lista de todos los nombres de archivos disponibles; las configuraciones y equipos de grabación; los nombres de los discos donde se almacenan; las áreas donde se realizaron las grabaciones; la lista de posibles usuarios que intervienen tanto en las grabaciones como en las detecciones y las distintos tipos de fuentes y sonidos.

En el presente estudio, los eventos de interés se consiguen a partir de la detección de sonidos mediante la inspección visual de sus espectrogramas y la posterior confirmación auditiva correspondiente. Para llevar a cabo esta tarea se utilizan programas especializados para inspección de espectros y señales temporales bioacústicas. En este caso en particular se usan PAMguard y Triton, este último disponible de forma gratuita para MATLAB.

Durante de ese proceso, se extrae la información necesaria para ser organizados y almacenados en la base de datos diseñada. Al cargar un evento detectado a la base de

datos debe especificarse: tipo de sonido, tipo de fuente, nombre de archivo, configuración utilizada en el espectrograma, segmentos temporales de detección y usuario. De esta forma se obtiene una base de datos con la cual realizar el entrenamiento del sistema de detección automático.

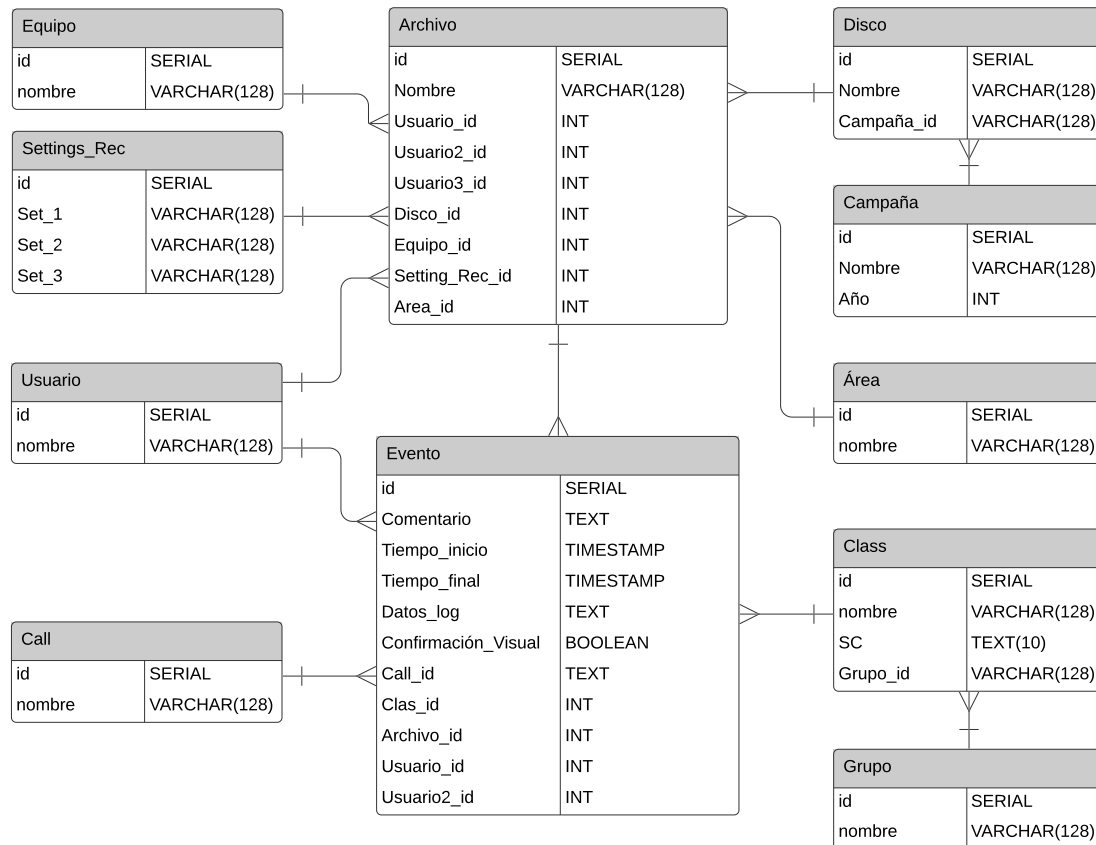


Figura 7. Diagrama entidad-relación de la BDR.

Dependiendo de la cantidad de eventos disponibles, la BDR se complementa con datos de bases de datos alternativas para conseguir una gran volumen de muestras suficientes como para lograr optimizar el nivel de aciertos del algoritmo. Vale la pena mencionar que los datos de BDR van a ser utilizados tanto en etapa de entrenamiento como para la validación.

3.2. COMPOSICIÓN DE LA BASE DE DATOS.

Como se menciona en la sección 3.1, para la conformación de la base de datos a utilizar para entrenar, probar y validar los algoritmos se utilizan diversas fuentes de

registros sonoros. Para el desarrollo de sistemas de detección automática basados en aprendizaje automático resulta necesario conformar una base de datos que cuente con 2 conjuntos de datos: embarcaciones (E) y no embarcaciones (NE). En ambos casos, para determinar que se encuentra, o no, un evento acústico generado por embarcaciones se realiza una inspección visual de sus espectrogramas.

En primer lugar, se analizan las bases de datos provistas por la Fundación Cethus. A partir de esta experiencia se obtienen 27 archivos de 1 minuto de duración. Se considera que esta cantidad de eventos acústicos es insuficiente para poder entrenar, probar y validar los algoritmos a desarrollar. Por lo tanto, se procede a buscar posibles bases de datos de público acceso en internet.

A partir de un extenso estudio de los distintos trabajos de investigación desarrollados, se encuentra que en la mayoría de los casos utilizan sus propias bases de datos privadas. Por esta razón, se intenta establecer contacto con sus autores para solicitar su colaboración. A consecuencia de esta operación se consiguen 30 grabaciones de 30 minutos de duración donde se encuentran registros de embarcaciones que posiblemente circularon por el Golfo Corcovado en la Patagonia chilena. Las mismas se obtuvieron a partir de la colaboración de la oceanógrafa inglesa Susannah Buchan. Por otro lado, a partir de un acuerdo de cooperación que establece la Fundación Cethus con Julia Dombroski se consigue el acceso a una base de datos conformada por grabaciones con una duración de 8 días y 23 horas realizadas en 2018 en la costa de Santa Catalina, Brasil.

Considerando la variabilidad de los registros acústicos conseguidos, se establece un formato para las muestras de audio con el objetivo de conseguir una estandarización para su posterior procesamiento. Cada evento que conforma la base de datos es de un único canal, con una duración de 1 minuto, 16 bits y una frecuencia de muestreo de 11025 Hz. Por lo tanto, se cuenta con un conjunto de datos total de 441(+X) muestras.

-(Aún no se sabe cuantas muestras útiles resultarán del aporte de Susannah ya que las grabaciones están con una fs de 250Hz. Se le respondió para que vuelva a enviarlas en su fs original de 2kHz pero suele demorar en responder)

- (De utilizar las muestras de Susannah en 2kHz cambiar la fs escrita arriba. Además, podrían no utilizarse porque hay posibles cambios en la firma acústica de pequeñas embarcaciones por encima de 1 kHz como se indica en el marco teórico).

Vale la pena mencionar que las 414 muestras del total provienen de fragmentos de 1 minuto de los archivos pre clasificados y anotados mediante la inspección visual de sus espectrogramas como "embarcaciones". Los mismos surgen a partir del procesamiento mediante el uso de un algoritmo de detección automática de eventos acústicos con alto contenido tonal de los casi de 9 días de grabaciones aportadas por Julia Dombroski. El algoritmo en cuestión es realizado de forma auxiliar para la presente investigación y es explicado en detalle en la sección 3.4.1.

Por otro lado, para el desarrollo de los algoritmos resulta necesaria la conformación de un conjunto de datos de eventos acústicos considerados como "no embarcaciones". Se obtienen 500 muestras a partir de secciones donde no se encuentran sonidos producidos por barcos provenientes de los mismos archivos utilizados.

3.3. ESTUDIO DE DESCRIPTORES

Debido a que las muestras que conforman los conjuntos de datos a utilizar para el entrenamiento de los algoritmos son una duración preestablecida, se descartan los descriptores temporales. La decisión de tomar muestras de una duración estandarizada se fundamenta en que las duraciones de los eventos acústicos generados de las embarcaciones son altamente variables. Estas diferencias se explicarían principalmente por las distintas direcciones de navegación mas que por las características acústicas de los barcos. Además, como los algoritmos desarrollados en la presente investigación serán utilizados en una plataforma de monitoreo acústico pasivo autónoma, el tiempo de procesamiento del detector debe ser definido y optimizado para ahorrar recursos computacionales.

A partir de la revisión del estado del arte de sistemas de detección y clasificación de ruido de embarcaciones es que se decide utilizar la firma acústica de los registros sonoros como descriptor principal del evento acústico. La misma se obtiene a partir de una reducción de la DFT en bandas de tercio de octava estandarizadas por la IEC 61260-3. Para los fines de esta investigación se utilizan las bandas definidas entre 5 y 4000 Hz.

Por otra parte, se decide calcular todos los descriptores espectrales que se detallan en la tabla 1 para luego evaluar la influencia de cada parámetro acústico sobre el rendimiento del algoritmo. El objetivo de esta metodología es el de determinar la mínima cantidad de parámetros de entrada que garantiza resultados satisfactorios buscando optimizar el costo computacional del algoritmo. Para ello se compara exactitud de los algoritmos para distintas combinaciones de descriptores. Este proceso se repite 10 veces para cada combinación.

3.4. DESARROLLO Y EXPERIMENTACIÓN CON ALGORITMOS.

Se decide desarrollar independientemente el sistema de detección del de clasificación automática de ruido de embarcaciones. Además resulta necesario el desarrollo de algoritmos auxiliares tanto para la obtención de las muestras que conforman la base de datos como para el pre-procesamiento de los archivos de audio.

3.4.1. DETECTOR AUTOMÁTICO DE EVENTOS ACÚSTICOS TONALES.

Debido a que se cuentan con largas grabaciones donde puede haber eventos acústicos provenientes de embarcaciones, surge la necesidad de implementar un algoritmo que permita pre filtrar para su posterior procesamiento. En primer lugar, se realiza una inspección visual de los espectrogramas de algunos de los archivos de audios hasta encontrar una pequeña cantidad de señales provenientes de barcos.

Los archivos provistos por Julia Dombroski son del tipo multicanal (conformados por registros obtenidos mediante un arreglo de 4 hidrófonos) de 30 minutos, grabados con una frecuencia de muestreo de 16 kHz y 16 bits por muestra. En la Figura 8 se muestra a modo de ejemplo la representación del espectrograma de detecciones manuales de embarcaciones. En el gráfico superior puede observarse la representación de 0 a 2,6 kHz mostrando la característica forma en U de su espectrograma mientras que en el gráfico inferior se observa en detalle el comportamiento tonal del evento acústico en cuestión.




Figura 8. Ejemplo de detección visual de embarcaciones en software Raven Pro 1.6.
Representación completa (arriba) y representación de su contenido tonal (abajo).

A partir de un estudio de sus características acústicas se desarrolla un algoritmo que discrimine los tiempos y nombres de archivos donde posiblemente hayan señales de interés. Se decide implementar un algoritmo de detección tonal como lógica de detección acústica de los eventos. A modo de facilitar su comprensión, en la Figura 9 se muestra un diagrama en bloques del código en cuestión.

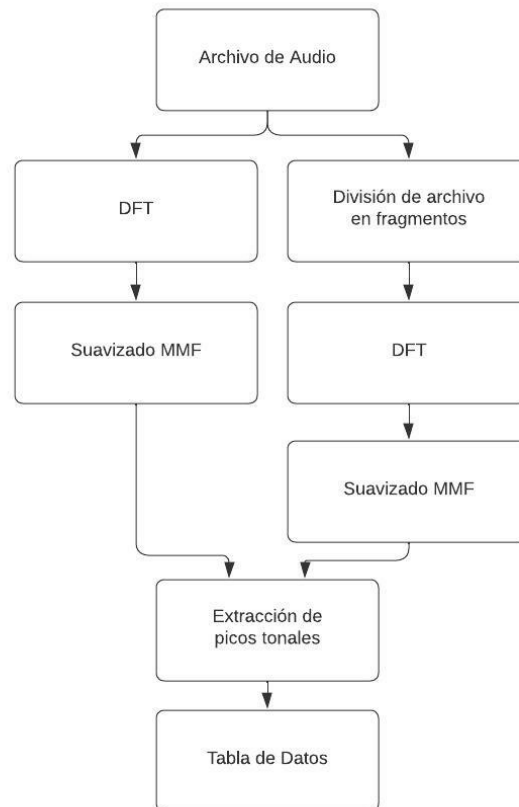


Figura 9. Diagrama en bloques del algoritmo de detección de señales tonales.

En primer lugar, se establece el directorio donde se realizará el procesamiento. Luego se carga un archivo y se dividen sus canales para analizarlos individualmente. Seguidamente se calcula su transformada de Fourier discreta (DFT por sus siglas en inglés), se descarta la información fuera del rango de 5 y 500 Hz y se suaviza su respuesta en frecuencia mediante la utilización de un filtro de media móvil (MMF). Por otro lado, se divide el mismo archivo en fragmentos de 1 minuto de duración y se realiza el mismo procesamiento.

A continuación, se procede a comparar la respuesta en frecuencia de cada fragmento con la correspondiente al archivo en su totalidad. Se localizan los picos que superen en un 50% el valor de amplitud de la respuesta en frecuencia del archivo completo. Posteriormente, se calcula el valor de amplitud promedio en rangos de frecuencias definidos entre $\pm 10\%$ de cada pico de frecuencia detectado. Se considera como señal con alto contenido tonal a los fragmentos donde la amplitud de por lo menos 2 picos detectados logren superar por 2 veces a la amplitud promedio de sus

correspondientes rangos de frecuencias asociados. Se establece que al menos suceda en 2 detecciones con el objetivo de reducir falsos positivos ya que por tratarse de sonidos tonales producto del funcionamiento de un motor, debiera producir un sonido con frecuencia fundamental y algunos armónicos. Por último, se genera un archivo con formato .csv donde se especifican los tiempos de detección, el nombre de cada archivo y el canal correspondiente. En la Figura 10 puede observarse la representación gráfica del proceso de obtención picos de frecuencias tonales.




Figura 10. Representación del proceso de detección de picos. Respuesta en frecuencia del archivo completo (azul), respuesta en frecuencia de fragmento con señal de interés (rojo) y detecciones de picos (cruces).

Vale la pena mencionar que los valores de umbrales y criterios de detección de picos tonales son tomados de forma arbitraria y surge de la propia experiencia empírica de trabajar y analizar las señales detectadas manualmente en una primer instancia. No se busca optimizar al máximo este primer algoritmo ya que la elección de muestras que conformarán la base de datos en última instancia se lleva a cabo a partir de la inspección visual de los espectrogramas de los archivos que presenten señales con contenido tonal.

3.4.2. PRE-PROCESAMIENTO.

A partir de las muestras de audio de embarcaciones y no embarcaciones se procede a calcular y obtener los distintos parámetros acústicos y variables que conforman el

conjunto de datos de entrenamiento y evaluación a utilizar por el algoritmo de detección automática. El proceso en cuestión consta de cuatro etapas: carga de archivos de audio; obtención de las respuestas en frecuencia; cálculo de parámetros acústicos y exportación de los resultados.

En primer lugar, se leen los nombres de todos los archivos que se encuentren dentro de un directorio establecido y se procede a cargar cada uno individualmente. Seguidamente, se normaliza con el objetivo de estandarizar las amplitudes de las señales. Este proceso es de vital importancia para independizarse del nivel que tenga cada señal.

Mediante el empleo de un algoritmo auxiliar se obtiene la respuesta en frecuencia en tercios de octava. De esta forma, se consigue una firma acústica en donde es notorio el contenido tonal del evento sonoro en cuestión. Si por el contrario se decidiera utilizar filtros de banda de octava, las características tonales se verían comprometidas por el proceso de integración energética que las conforma. La firma acústica surge del procesamiento de cada fragmento mediante filtros de sexto orden, dando como resultado 30 valores correspondiente a bandas de frecuencia entre 5 y 4000 Hz. Se decide utilizar este rango de frecuencias ya que es donde se supone que se almacena la mayor cantidad de información del evento acústico en cuestión. Finalmente, buscando optimizar el proceso de aprendizaje del algoritmo de detección cada firma acústica es normalizada. Se dividen los valores de las bandas por el máximo de la firma acústica y de esta manera se logra una representación energética con un valor máximo de 1. Esta normalización puede hacerse ya que la información relevante en la firma acústica es la relación de amplitudes entre bandas de frecuencia en lugar de los valor absolutos de las mismas.

Seguidamente se procede a calcular los parámetros acústicos. Como se busca desarrollar un algoritmo para ser implementado posteriormente en una estación de monitoreo acústico pasivo, resulta conveniente minimizar la influencia de las distintas posiciones y direcciones de navegación de las embarcaciones. Esta es la razón por la cual se decide utilizar únicamente parámetros que surgen de la respuesta en frecuencia. Por lo tanto, se calcula frecuencia central, centroide espectral, frecuencia 5%, frecuencia 95% y ancho de banda 90% a partir de su respuesta en frecuencia. Tal y como para el caso de la firma acústica resulta necesario normalizar los parámetros con el objetivo de optimizar el aprendizaje del algoritmo de detección. En este caso en particular, se calcula el valor

medio y desvío estándar de cada parámetro obtenido en el total de cada conjunto de datos y se normaliza utilizando la ecuación 4. De esta forma se consigue normalizar cada parámetro para tener una media cercana a 0 y así obtener mejores resultados a la hora de entrenar el algoritmo de detección.

Por último, el algoritmo se encarga de concatenar la firma acústica y los parámetros calculados en vectores para almacenarlos y exportarlos en un archivo con formato .csv. Mediante el procesamiento de los 2 grupos de eventos acústicos (E y NE) y se consiguen los conjuntos de datos necesarios para entrenar el detector automático.

3.4.3. DETECTOR AUTOMÁTICO DE EMBARCACIONES.

Se desarrolla el algoritmo de detección basado en una red neuronal artificial básica en la cual puedan modificarse fácilmente las distintas configuraciones de la misma con el objetivo de evaluar y comparar su desempeño. Para esta experiencia se utiliza un framework de alto nivel llamado keras. El mismo fue desarrollado con el objetivo de facilitar el proceso de experimentación utilizando otras librerías como TensorFlow por lo que resulta de gran utilidad para los fines del presente desarrollo.

En primer una primer instancia, se dividen los conjuntos de datos en 70% de las muestras para entrenamiento y 30 % para evaluación. Luego, se experimenta con la estructura de la red neuronal, variando cantidad de neuronas y cantidad de capas y se elige la configuración que consiga resultados satisfactorios con menor cantidad de neuronas y capas. Para que tenga sentido la comparación resulta necesario fijar los demás parámetros que intervienen en el aprendizaje de una red neuronal. En este caso en particular, se establece que se utilizarán 100 epochs, un batch size de 64 muestras y una tasa de aprendizaje del 0.01.

Se lleva a cabo el entrenamiento de cinco distintas redes neuronales de 2, 3 y 4 capas variando la cantidad de neuronas. Se entrena una red de 2 capa con una estructura de cinco neuronas en la primer capa y una neurona en la segunda (5-1). Luego se incrementa a 20 la cantidad de neuronas de la primer capa (20-1). Seguidamente, se entrena una red de 3 capas con una estructura 7-5-1. Posteriormente se entrena la misma red modificando la cantidad de neuronas a 20-12-1. Por último se entrena la red de 4 capas conformada por 20, 12, 5 y 1 neuronas.

Mediante una experimentación similar a la previamente explicada se establecen los valores de parámetros que optimizan la red neuronal llegando al punto de equilibrio de aprendizaje. Es decir, se encuentra la configuración que maximice la cantidad de detecciones sobre el conjunto de evaluación sin producir un sobreajuste del algoritmo. Por último, una vez definida tanto la estructura de la red neuronal como los parámetros de aprendizaje, se procede a entrenar y evaluar la precisión de detección del algoritmo. Vale la pena mencionar que resulta necesario repetir sucesivamente cada experiencia con el objetivo de conseguir resultados representativos del experimento y no los de un caso aislado. Por lo tanto se decide repetir 10 veces cada intervención en la configuración del algoritmo.

Por último se evalúa la influencia producto de la variación en la cantidad de muestras disponibles en la base de datos. En este caso, desde 100 muestras a una tasa de incremento 50 muestras hasta llegar al límite superior disponible hasta la fecha. Los resultados se grafican y ajustan mediante el uso de una ecuación matemática para estimar la tasa de cambio en la precisión del algoritmo. Nuevamente, los valores se calculan como el promedio de los resultados de diez entrenamientos para cada tamaño del conjunto de datos.

3.4.4. CLASIFICADOR DE EMBARCACIONES.

A desarrollar post presentación de los avances hechos durante el transcurso de la materia.

4. RESULTADOS

4.1. DETECTOR AUTOMÁTICO DE EVENTOS ACÚSTICOS TONALES.

A partir del procesamiento de los 430 archivos correspondiente a los 8 días y 23 horas de grabaciones conseguidas se obtienen 289 detecciones de alto contenido tonal dentro de 96 archivos. Luego, se realiza mediante la inspección visual de las detecciones se descartan los archivos donde no se observan embarcaciones o donde tiene una relación señal considerablemente baja. A partir de dicha actividad, se llega a la conclusión de que 182 de las detecciones resultaron ser de embarcaciones. Por este motivo es que se supone que el algoritmo tiene cerca de un 63% de detecciones positivas reales. De igual manera, para los fines de la presente investigación no resulta de interés la caracterización de este algoritmo en particular ya que se trata de una herramienta auxiliar.

Una vez conocidos los archivos donde se tienen registros de embarcaciones se procede a obtener muestras de 1 minuto de duración. Esta actividad se realiza a partir de un proceso de recorte manual de fragmentos de archivos en donde la señal de interés sea fácilmente discriminable por medio de la inspección visual de su espectrograma. Mediante el desarrollo de este proceso se extraen 414 muestras que servirán para entrenar, probar y validar los algoritmos de detección y clasificación automática.

4.2. CARACTERIZACIÓN DE SEÑALES.

En primer lugar, se realiza el test de normalidad de Kolmogorov-Smirnov para determinar si los descriptores extraídos siguen una distribución normal. Se encuentra que solo el centroide espectral y la frecuencia 5% son similares a una distribución normal (con un nivel de significancia del 0.05). Para los demás parámetros se obtiene la mediana y los cuartiles 25% (Q1) y 75% (Q3) como parámetros estadísticos representativos. Los resultados obtenidos se representan en la Tabla 2.

Tabla 2. Media \pm desvío estándar para frecuencia 5% y centroide espectral. Mediana (Q1-Q3) para el resto de los descriptores.

Parámetro	Media / Mediana	Desvío / (Q1-Q3)
Frecuencia Pico [Hz]	101.3	(60.9 - 133.9)
Frecuencia Central	519.3	(311.4 - 903.8)
Centroide Espectral	1340.1	464.9
Ancho de banda 90%	4531.2	(4230.1 - 4736.7)
Frecuencia 5% [Hz]	65.9	35.6
Frecuencia 95%	4600.3	(4296.4 - 4808.7)

Como primer observación, el resultado de la frecuencia pico se corresponden a lo esperado ya que se observa en torno a los 100 Hz. Esto resulta consistente con el componente tonal producto de la cavitación generada por la rotación de hélices que se menciona en el marco teórico. Además, a partir de la frecuencia central puede asumirse que la mayor proporción de energía se concentra en el rango de bajas frecuencias. Este parámetro informa que entre 5 y 520 Hz se tiene la misma cantidad de energía que entre 520 y 5512 Hz. Vale la pena mencionar que la frecuencia superior está determinada por la frecuencia de muestreo (11025 Hz). Esta información también es consistente con lo mencionado en el marco teórico, ya que si bien se presenta energía hasta los 4600 Hz, esta es producto de la interferencia entre los distintos caminos de propagación del sonido.

Por otro lado, se encuentran frecuencias 95% cercanas a los 4.6 kHz por lo cual la decisión de establecer como banda superior de la firma acústica la banda de 4 kHz se

considera una decisión acertada, ya que esto implica que la mayoría de la energía se observa en este rango de frecuencias.

4.3. DETECTOR AUTOMÁTICO DE EMBARCACIONES.

Los resultados obtenidos a partir de la evaluación de las distintas estructuras de redes neuronales se muestran en la Tabla 3. En primer lugar, se descarta la red 5-1 ya que es la única que tiene una precisión considerablemente inferior. Debido a que se obtienen resultados considerablemente similares en todos los otros casos, la estructura se elige en función de una relación de compromiso entre menor cantidad de parámetros, asociados al costo computacional del algoritmo, y la exactitud. Por lo tanto, se elige trabajar con una red neuronal de estructura 7-5-1.

Tabla 3. Resultados de experimentación con distintas estructuras de redes neuronales.

Estructura de Red Neuronal	Exactitud	Cantidad de Parámetros
5-1	73.37%	186
20-1	78.2%	741
7-5-1	78.6%	298
20-12-1	79.6%	985
20-12-5-1	80.4%	1043

En las Figuras 11 y 12 se representa como varía la exactitud y el error de detección para los conjuntos de datos de entrenamiento y evaluación en función de epochs. A partir de las mismas se determina que el valor de 190 epochs brinda resultados satisfactorios evitando el sobreajuste de los parámetros al conjunto de entrenamiento. Para esta

configuración el modelo arroja una precisión del 89.89% para el conjunto de entrenamiento mientras que del 87.51% para el de evaluación.




Figura 11. Representación precisión de detección en función de la cantidad de epochs.

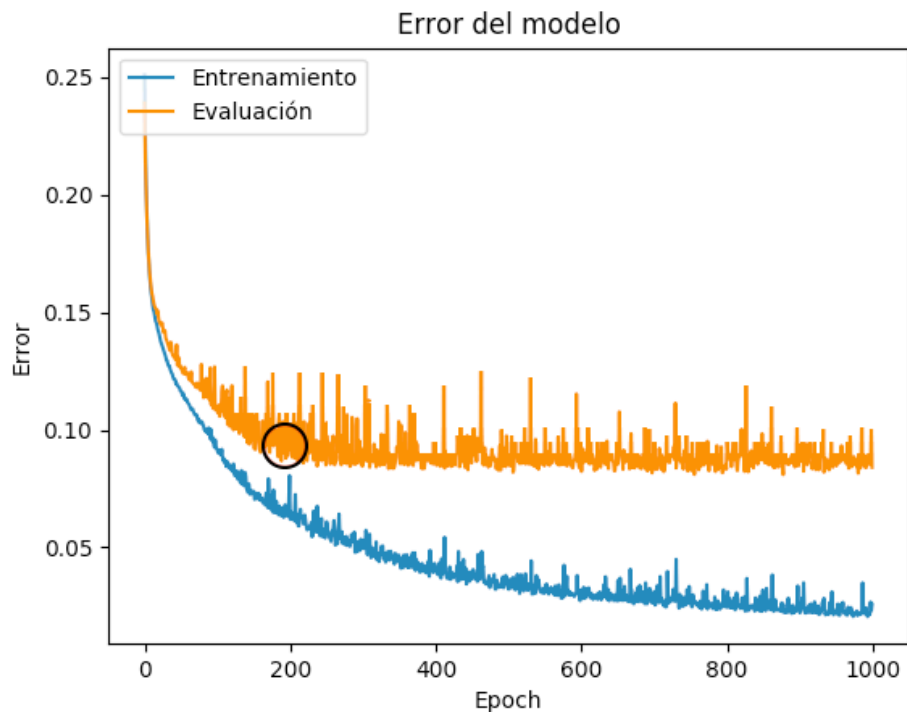


Figura 12. Representación del error de detección en función de la cantidad de epochs.

Vale la pena mencionar que estos resultados son en base a utilizar la totalidad de los descriptores espectrales en conjunto con la firma acústica. Se supone que al reducir la cantidad de descriptores se debería empeorar el desempeño del algoritmo. Por lo tanto, la experimentación que busca optimizar la cantidad de parámetros acústicos a utilizar se realiza luego de definir la estructura de la red neuronal.

4.3.1. ESTUDIO DE DESCRIPTORES.

En esta sección se estudia la influencia de cada parámetro sobre el desempeño del algoritmo de detección. Para esto, se compara la exactitud sobre el conjunto de datos de evaluación realizando el entrenamiento con distintos grupos de descriptores. Los mismos son elegidos inteligentemente con el objetivo de evitar entrenar al algoritmo sobre todas combinaciones posibles, lo cual se volvería un proceso largo y tedioso. Para cada uno de ellos el proceso de entrenamiento se repite 10 veces y se promedia el resultado con el objetivo de evitar valores de exactitud atípicos. En primer lugar se entrena al algoritmo eliminando un único parámetro. En la tabla 4 se muestran los resultados de dicha experiencia.

Tabla 4. Resultados de experimentación descartando de a un parámetro.

Prueba	Exactitud
Completo	87.90%
Sin Fp	86.40%
Sin F _{5%}	87.20%
Sin F _{95%}	86.27%
Sin B _{90%}	87.27%

Sin Ce	87.04%
Sin Fc	87.88%
Sin Fa	81.41%

A partir de esta experiencia puede observarse una gran disminución de la exactitud al prescindir de la firma acústica (Fa). Por lo cual, este se considera a priori el que mayor influencia el desempeño del algoritmo. Para verificar esta hipótesis se entrena al sistema únicamente con dicho descriptor dando como resultado una exactitud del 85.68%. Por lo tanto, para las posteriores pruebas se decide utilizarlo. Por otro lado, se observa que despreciar la frecuencia central (Fc) no produce grandes cambios en la respuesta por lo que se realiza un nuevo ciclo de entrenamiento donde se excluye el mismo y se prueba la influencia de los demás descriptores. En la tabla 5 se muestran los resultados la prueba.

Tabla 5. Resultados de experimentación descartando a Fc y otro parámetro.

Prueba (sin Fc)	Exactitud
Completo	87.90%
Sin Fp	86.11%
Sin F _{5%}	87.01%
Sin F _{95%}	86.94%
Sin B _{90%}	87.04%
Sin Ce	87.04%

A partir de los resultados obtenidos puede afirmarse que en ningún caso se observa grandes cambios pero si una sutil disminución en la exactitud a medida que se eliminan parámetros acústicos. A partir de la prueba que se realiza entrenando a la red neuronal únicamente con la firma acústica se asume que el desempeño del algoritmo se reducirá hasta el conseguido a partir de la misma. Por otro lado, si se busca la reducción del costo computacional al eliminar descriptores, el único que representaría un gran beneficio al ser descartado es el de la firma acústica ya que este se obtiene a partir de un filtrado por bandas de tercio de octava y es representado por 30 elementos. Asimismo, el cálculo de los demás parámetros acústicos se realiza sobre la DFT. Estas son las razones por las se considera que despreciar un único parámetro (F_c) no representa una sustancial reducción de costo computacional. Por otro lado, si se quisiera optimizar el algoritmo descartando todos los parámetros acústicos obtenidos utilizando la DFT, se consigue una disminución en la exactitud. Esto último pudo comprobarse en el caso de entrenar a la red neuronal solo con la F_a . Por lo tanto, se decide conservar todos los descriptores utilizados hasta el momento.

4.3.2. TAMAÑO DE BASE DE DATOS.

Otro de los factores a tener en cuenta al crear un sistema basado en redes neuronales es el número de muestras que se utiliza en la etapa de entrenamiento. Por lo tanto, habiendo definido la estructura de la red neuronal, se lleva a cabo su entrenamiento para distinta cantidad de muestras. Se decide utilizar la misma cantidad de datos pertenecientes a ambas clases con el objetivo de minimizar posibles errores producto del desbalanceamiento entre conjuntos de datos. Como se menciona en la sección 2.8.2, si se evalúa la exactitud en un modelo que utiliza grupos no balanceados se obtendrían imprecisiones en los resultados.

Se comienza con un conjunto de entrenamiento de 200 muestras en total (100 de cada clase) hasta llegar al límite superior de muestras disponibles hasta la fecha, es decir, 441 eventos. En cada caso el proceso de entrenamiento se repite 10 veces y se promedia el resultado con el objetivo de evitar valores de exactitud atípicos. En la Figura 13 se muestran los resultados obtenidos.




Figura 13. Representación de la exactitud del modelo en función la variación de cientos de muestras del conjunto de registros de embarcaciones.

En primer lugar, vale la pena mencionar que la representación se lleva a cabo en función de cientos de muestras con el objetivo de que la ecuación que describe el ajuste lineal esté relacionada a variaciones de estas magnitudes en el conjunto de datos. De esta forma se vuelve mas notable el impacto que produce el incremento de cientos de muestras sobre la precisión del algoritmo. En este sentido, se observa un incremento del 0,019% cada cien muestras lo que a priori permite suponer que de mantenerse esta tendencia, si se utilizaran 800 muestras de cada tipo se conseguiría una exactitud del orden del 96%. De esta forma, la presente experiencia sugiere un efecto positivo en la incorporación de muestras a las bases de datos. Cabe destacar que si bien se espera una mejora en la precisión al incrementar la cantidad de muestras, es esperable que el algoritmo tienda a estabilizarse en un valor máximo de exactitud. Tal evaluación podría realizarse a futuro en nuevas instancias de entrenamiento utilizando grandes conjuntos de datos.

ACTIVIDADES PENDIENTES Y/O EN PROCESO:

Post Presentación de tesis:

- Desarrollar algoritmos de clasificación entre barcos.
- Evaluación y validación
- Redacción
- Posibles mejoras en los datasets a utilizar para los algoritmos
- Redacción

5. CONCLUSIONES

6. LÍNEAS FUTURAS DE INVESTIGACIÓN

BIBLIOGRAFÍA

- [1] Evans, D.L., England, G.R.E. "Joint interim report Bahamas Marine Mammal Stranding Event of 15-16 March 2000". Tech. Rep., US Department of Commerce and Secretary of Navy. 59 pp. 747-756. December 2001.
- [2] Lucke, K., Siebert, U., Lepper, P.A., Blanchet, M.A. "Temporary shift in masked hearing thresholds in a harbor porpoise (*Phocoena phocoena*) after exposure to seismic airgun stimuli". *J. Acoust. Soc. Am.* 125, pp. 4060-4070. Jun 2009.
- [3] Bailey, H., Senior, B., Simmons, D., Rusin, J., Picken, G., Thompson, P.M. "Assessing underwater noise levels during pile-driving at an offshore windfarm and its potential effects on marine mammals". *Marine Pollution Bulletin* 60, pp. 888-897. 2010.
- [4] Richardson, W.J., Würsig, B. "Influences of man-made noise and other human actions on cetacean behaviour". *Marine and Freshwater Behaviour and Physiology* 29, pp. 183-209. 1997.
- [5] Popper, A.N., Hastings, M.C. "The effects of anthropogenic sources of sound on fishes". *Journal of Fish Biology* 75, pp. 455-489. 2009.
- [6] André, M., Solé, M., Lenoir, M., Durfort, M., Quero, C., Mas, A., Lombarte, A., van der Schaar, M., López-Bejar, M., Morell, M., Zaugg, S., Houégnigan, L. "Low-frequency sounds induce acoustic trauma in cephalopods". *Frontiers in Ecology and the Environment* 9, pp. 489-493. 2011.
- [7] Clark, C.W., Ellison, W.T., Southall, B.L. Hatch, L., Van Parijs, S.M. Frankel, A., Ponirakis, D. "Acoustic masking in marine ecosystem: intuitions analysis, and implication". *Marine Ecology Progress Series* 395. pp. 201-222. 2009.
- [8] Wright, A.J., Soto, N.A., Baldwin, A.L., Bateson, M., Beale, C.M., Clark, C., Deak, T., Edwards, E.F., Fernandez, A., Godinho, A., Hatch, L.T., Kakuschke, A., Lusseau, D., Martineu, D., Romero, M.L., Weilgart, L.S., Wintle, B.A., Notarbartolo-di Sciara, G., Martin, V. "Do marine mammals experience stress related to anthropogenic noise?". *International Journal of Comparative Psychology* 20, pp. 274-316. 2007.
- [9] Picciulin, M., Sebastianutto, L., Codarin, A., Farina, A., Ferrero, E.A. "In situ behavioural responses to boat noise exposure of *Gobius cruentatus* and *Chromis chromis* living in a

Marine Protected Area". *Journal of Experimental Marine Biology and Ecology* 386. pp. 125-132. 2008.

[10] Chan, A., Giraldo-Perez, P., Smith, S., Blumstein, D.T. "Anthropogenic noise affects risk assessment and attention: the distracted prey hypothesis". *Biology Letters* 6, pp. 458-461. 2010.

[11] Fundación Cethus, Lineas de investigación, Extraído el 19 de Agosto de 2021, www.cethus.org

[12] Shiu, Y., Palmer, K. J., Roch, M. A., Fleishman, E., Liu, X., Nosal, E. M., Helbe T., Cholewiak, D., Gillispie, D., Klinck, H. "Deep neural networks for automated detection of marine mammal species". *Nature Research*. 2020.

[13] Erbe, C. "Underwater passive acoustic monitoring & noise impacts on marine fauna". *Australian Acoustical Society*. Enero 2013.

[14] Gardiner, J., Morrin, E., Todd, I., Todd, E., *Marine Mammal Observer & Passive Acoustic Monitoring Handbook*, 1er edición, Pelagic Publishin, Reino Unido. 2015.

[15] McKenna, M.F., Ross, D., Wiggins, S.M., Hildebrand, J.A. "Underwater radiated noise from modern commercial ships". *Journal of the Acoustical Society of America* 131, pp. 92–103. 2012.

[16] Wales, S., Heitmeyer, R. "An ensemble source spectra model for merchant ship-radiated noise," *Journal of the Acoustical Society of América* 111, pp. 1211–1231. 2002.

[17] Wilmut, M. J., Chapman, N. R., Heard, G. J., Ebbeson, G. R. "Inversion of Lloyd Mirror Field for determining a source's track," *IEEE J. Ocean. Eng.* 32, pp. 940–947. 2007.

[18] Jensen, F.H., Bejder, L., Wahlberg, M., Soto, N.A., Johnson, M., Madsen, P.T. "Vessel noise effects on delphinid communication". *Marine Ecology Progress Series* 395, pp. 161–175. 2009-b.

[19] Abrahamsen, K., "The ship as an underwater noise source". *Acoustical Society of America*. 2012.

[20] IEC-International Electrotechnical Commision, *Electroacoustics - Octave-band and fractional-octave-band filters. Part 3: Periodic tests*, 2016.

- [21] Blackwell, S. B., Natopms, C. S., McDonald T. L., Thode, A. M., Mathias, D., Kim, K. H., Greene C. R. Jr, Macrander M. A., "Effects of airgun sounds on bowhead whale calling rates: evidence for two behavioral thresholds". *Journal Plos One* 10. 2015.
- [22] Hildebrand, J. A., Baumann-Pickering, S., Frasier, K. E., Trickey, J. S., Merkens, K. P., Wiggins, S. M., McDonald M. A., Garrison, L. P., Harris, D., Marques, T. A., Thomas, L. "Passive acoustic monitoring of beaked whale densities in the Gulf of Mexico". *Sci. Rep* 5. 2015.
- [23] Ciresan, D. C., Meier, U., Masci, J., Schmidhuber, J. "A committee of neural networks for traffic sign classification". *Proc. Int. Jt. Conf. Neural Netw.USA*. 2011.
- [24] Steiner, W. W. "Species-specific differences in pure tonal whistle vocalizations of five western North Atlantic dolphin species". *Behav. Ecol. Sociobiol.* 9, pp. 241–246. 1981.
- [25] Roch, M., Soldevilla, M., Hildebrand, J. "Automatic species identification of odontocete calls in the Southern California Bight". *J. Acoust. Soc. Am.* 116, pp. 2614–2614. 2004.
- [26] Fagerlund, S. "Bird species recognition using support vector machines". *EURASIP J. Adv. Signal Process*, pp. 64–64. 2007.
- [27] Oswald, J. N., Barlow, J., Norris, T. F. "Acoustic identification of nine delphinid species in the eastern tropical Pacific Ocean". *Mar. Mammal. Sci.* 19, pp. 20–37, 2003.
- [28] Gradišek, A., Slapničar, S., Šorn, J., Luštrek, M., Gams, M., Grad, J. "Predicting species identity of bumblebees through analysis of flight buzzing sounds". *Bioacoustics* 26, pp. 63–76. 2017.
- [29] Guilment, T., Socheleau, F.-X., Pastor, D., Vallez, S. "Sparse representation-based classification of mysticete calls". *J. Acoust. Soc. Am.* 144, pp. 1550–1563. 2018.
- [30] Halkias, X. C., Paris, S., Glotin, H. "Classification of mysticete sounds using machine learning techniques". *J. Acoust. Soc. Am.* 134, pp. 3496–3505. 2013.
- [31] Kahl, S., Wilhelm-Stein, T., Klinck, H., Kowerko, D., Eibl, M. "Recognizing Birds from Sound". *The 2018 BirdCLEF Baseline System*. 2018.
- [32] Zhang, Y.-J., Huang, J.-F., Gong, N., Ling, Z.-H., Hu, Y. "Automatic detection and classification of marmoset vocalizations using deep and recurrent neural networks". *J. Acoust. Soc. Am.* 144, pp. 478–487. 2018.

- [33] Thomas, M., Martin, B., Kowarski, K., Gaudet, B. Matwin, S. "Marine mammal species classification using convolutional neural networks and a novel acoustic representation". European Conference on Machine Learning and Principles and Practice of Knowledge Discovery in Databases, Würzburg, Germany. 2019.
- [34] Ng., A., "Machine learning." Curso Online de la Universidad de Stanford, Julio 2016.
- [35] Marafioti, A., Identificación automática de instrumentos musicales acústicos a partir de señales monofónicas digitales, Tesis de Grado, Universidad Nacional de Tres de Febrero, (2016).

ANEXO I.